

Marketplace Safety

Case: en marknadsplats-app där teamet behöver prioritera misstänkt innehåll för manuell granskning.

Vårt uppdrag

Vi bygger ett enkelt beslutsstöd som hjälper Customer Support att prioritera vad som ska granskas först

- Målet är inte att få allt rätt, utan att prioritera rimligt
- Fokus är att minska onödiga flaggningar och skydda användarnas förtroende

Kravkort 8 – Lina, Customer Support

- Minimera onödiga flaggningar
- Rimlig och konsekvent prioritering
- Lösningen ska vara enkel att förklara

Ansvar i gruppen

Jonas – EDA

Marcus – Pipeline & preprocessing

Henry – Modelljämförelse

Henrik – Tuning och presentation

Ali – Threshold / prioritering och new_data.csv

Data och EDA


Vad vi såg i historical_data.csv

Det viktigaste vi såg

- Datan är obalanserad, så accuracy ensam blir missvisande.
- Nya konton verkar oftare hänga ihop med misstänkta händelser.
- Det finns saknade värden som pipeline måste kunna hantera.

Snabb fakta

- 12 000 rader
- 18 kolumner
- Target is_suspicious
- Andel misstänkta: 10.2 %
- Missing values i bl.a price, time_to_first_response_min och region



Vad detta betyder

- Det finns användbara signaler i datan
- Men modellen måste vara försiktig
- Annars riskerar vi att flagga vanliga användare

Pipeline och hur vi undvek leakage

En enkel och reproducerbar process



Varför pipeline?

- Samma steg användes varje gång genom hela utvärderingen
- Det minskade risken för manuella fel och gjorde modelljämförelsen mer jämförbar och rättvis

Leakage och cross-validation

- Preprocessing anpassades bara på träningsdata och applicerades sedan på val/testdata
- Samma pipeline användes även i 5-fold stratified cross-validation

Modelljämförelse

Dummy-baseline och tre modeller

CV-resultat

Modell	Accuracy	Precision	Recall	F1
Dummy-baseline	0,898	0,000	0,000	0,000
Logistic Regression	0,899	0,590	0,047	0,086
Random Forest	0,898	0,528	0,018	0,034
Decision Tree	0,827	0,186	0,207	0,195

Hur vi tänkte

- Accuracy räcker inte när datan är obalanserad
- För vårt kravkort blev precision extra viktig

Varför vi valde Logistic Regression

- Högst precision bland de testade modellerna
- Mer stabil än Decision Tree i vårt case
- Passar bättre när vi vill undvika onödiga flaggningar

Vald modell och tuning

Vi gick vidare med Logistic Regression och finjusterade modellen med GridSearchCV

Vald modell

Logistic Regression

Vi gick vidare med Logistic Regression och finjusterade modellen med GridSearchCV.

Vad vi testade

- **C:** 0.1, 1, 10
- **class_weight:** None eller balanced
- **Scoring i GridSearchCV:** precision

Resultat

Bästa parametrar
C = 10
class_weight = None

Bästa CV-precision
0,595

Vår tolkning

- En försiktig modell passade Lina bättre
- När vi testade balanced blev modellen mer aggressiv än vi ville
- Vi prioriterade färre men rimligare flaggningar

Threshold, prioritering och policy

Hur modellen används i praktiken

Threshold-jämförelse

Threshold	Flaggade	False positives	Precision
0,61	12	5	58,3 %
0,62	11	4	63,6 %
0,63	9	4	55,6 %
0,64	9	4	55,6 %

Vi rekommenderar threshold 0,62

Den gav högst precision i vår finjustering och låg bäst i linje med en försiktig prioriter

Top-10 kan användas som alternativ strategi vid mycket begränsad granskningskapacitet.

Kort policy när någon flaggas

- Ingen automatisk permanent avstängning
- Tillfällig paus eller mjuk friktion
- Extra verifiering vid behov

Exempel på false positive

Ett legitimt fall flaggades trots att användaren inte var misstänkt.

Exempel på signaler i raden:

- `account_age_days` = 20.4
- `prev_reports_30d` = 2
- `verification_level` = 0
- `urgency_words` = 1

Det visar att vissa risksignaler också kan finnas hos legitima användare.

Resultat på new_data.csv

Hur modellen prioriterade 2 000 nya händelser med threshold 0.62

Resultat på ny data

- Vi körde den färdiga modellen på **2 000 nya, osedda händelser**.
- Med **threshold 0.62** flaggades **7 fall** för manuell granskning.
- Det motsvarar en arbetsbörda på **0,4 %** av alla händelser.
- Fallen sorterades efter **risk_score** för prioritering.

Tolkning

- **new_data.csv** saknar facit, så vi kan inte mäta precision eller recall här.
- Däremot ser modellen ut att vara **försiktig** och hålla nere arbetsbördan.
- Det ligger i linje med kravkortet från Customer Support.

Topp 5 högst risk score

- ID 1092 — 0.8057
- ID 1398 — 0.7392
- ID 1547 — 0.6850
- ID 1130 — 0.6656
- ID 1831 — 0.6416
- Samtliga ovan låg över threshold 0.62 och flaggades för granskning.

Risker, begränsningar och nästa steg

Vad vi behöver tänka på i praktiken

Risker

- Vi kan fortfarande få false positives.
- En försiktig modell missar också en del misstänkta fall.
- Modellen ska användas som beslutsstöd, inte som automatisk avstängning.

Begränsningar

- Modellen bygger bara på de features som finns i datan.
- Det finns missing values och begränsad information i varje rad.
- Om beteenden ändras över tid kan modellen tappa kvalitet.

Nästa steg

- Följa upp utfall och feedback från Customer Support.
- Testa fler features och bättre risk-signaler.
- Övervaka drift och uppdatera modellen vid behov.

Slutsats: Vi rekommenderar en försiktig modell, threshold 0.62 och mjuk hantering av flaggade fall.